

MASt3RベースGaussian Splattingパイプライン 技術仕様書

1.0 概要

本ドキュメントは、現代の3D再構築における二つの大きな課題—すなわち、従来のStructure from Motion (SfM)の複雑性と、一般的なハードウェアの性能制約—を解決するために設計された、3D再構築パイプラインの技術仕様書です。本パイプラインは、2D画像コレクションから高忠実度な3Dシーンを生成するプロセスを民主化することを目的としています。その中核をなすのは、従来のSfMツールを深層学習モデルMASt3Rに置き換えるという戦略的判断であり、これにより初期再構築プロセスが大幅に効率化され、エンドツーエンドの自動化ワークフローが実現します。本仕様書では、パイプラインのアーキテクチャ、各構成要素の技術的詳細、そしてその設計を支える主要な技術的決定事項について詳述します。これにより、開発者および運用担当者は、本システムの全体像と動作原理を正確に理解することができます。続くセクションでは、パイプラインの実行に不可欠な環境構築の要件について詳述します。

1.1 パイプラインの目的と特徴

本パイプラインの主目的は、複数枚の2D画像から高品質な3Dシーンを生成するプロセスを自動化することです。その実現のために、以下の主要な特徴を備えています。

- **MASt3RによるSfMプロセスの代替:** 従来、特徴点マッチングやカメラ姿勢推定に用いられていたCOLMAPなどのSfMツール群を、単一の深層学習モデルMASt3Rで代替します。これにより、初期の3D再構築プロセスが簡素化され、ワークフロー全体が効率化されます。
- **DINOベースのインテリジェントなペア選定:** DINOv2モデルを用いて各画像のグローバルな特徴量を抽出し、画像間の類似度を計算します。これにより、3D再構築に最も寄与する可能性の高い画像ペアをインテリジェントに選定し、不要な計算負荷を削減します。
- **Biplet-Square Normalization:** 画像の向き(縦長・横長)に応じて2つの重複する正方形のクロップ(横長なら左右、縦長なら上下)を生成する、独自のデュアルクロップ戦略を採用しています。これにより、画像の周辺情報を最大限に保持したまま、後続処理のために画像サイズを標準化します。
- **厳密なメモリ管理:** 画像リサイズ、ペア数の制限、ポイントクラウドのダウンサンプリングなど、複数の手法を駆使してメモリ効率を徹底的に追求しています。これにより、GPUメモリなどのハードウェアリソースが限られた環境でも安定した動作を可能にします。
- **エンドツーエンドの自動化:** 依存関係のインストールから、データ前処理、3D再構築、そして最終的なGaussian Splattingモデルの学習まで、全工程を網羅する包括的なフレームワークとして機能します。

1.2 アーキテクチャ全体像

本パイプラインは、以下の連続したステージから構成される、直線的なデータフローアーキテクチャを採用しています。

- 環境構築:
- 入力: なし
- 処理: システムの基本的な依存関係、MASt3R、およびGaussian Splattingのリポジトリとサブモジュールをインストール・設定します。
- 出力: 実行可能なパイプライン環境
- 画像の前処理:
- 入力: 元の2D画像群

- 処理: 各画像に対してBiplet-Square Normalizationを適用し、標準化された正方形のクロップ画像を生成します。
- 出力: 処理済みの画像群
- 画像ペアの選定:
 - 入力: 処理済みの画像群
 - 処理: DINOv2モデルを用いて各画像からグローバル特徴量を抽出し、類似度に基づいて最適な画像ペアを選定します。
 - 出力: 再構築に使用する画像ペアのリスト
- **MASt3Rによる3D再構築:**
 - 入力: 処理済み画像群と選定された画像ペア
 - 処理: MASt3Rモデルが画像ペアを入力として受け取り、推論を実行します。
 - 出力: グローバルに位置合わせされたポイントクラウド (pts3d) とカメラポーズ (camera-to-world) を内包する scene オブジェクト
- **COLMAP形式への変換:**
 - 入力: MASt3Rが出力した scene オブジェクト
 - 処理: MASt3Rの出力をCOLMAPのバイナリ形式に変換します。このプロセスには、ポーズの反転 (world-to-cameraへの変換) と カメラ内部パラメータのスケーリング が含まれます。
 - 出力: cameras.bin, images.bin, points3D.binの3つのファイル
- **Gaussian Splattingモデルの学習:**
 - 入力: COLMAP形式のデータと処理済み画像群
 - 処理: COLMAPデータを基に、Gaussian Splattingモデルの学習を実行します。
 - 出力: レンダリング可能な3Dシーンモデル (point_cloud.ply)

2.0 環境構築

パイプラインの安定した実行を保証するため、環境構築フェーズは極めて重要です。この初期ステージでは、基本的なPythonライブラリから、MASt3RやGaussian Splattingといった専門的なフレームワーク、さらにはそれらのサブモジュールに至るまで、全ての依存関係が正確にインストール・設定されます。この基盤が正しく構築されることで、後続の複雑な計算処理が円滑に進行します。

2.1 基本的な依存関係

パイプラインの基盤となるライブラリ群は`setup_base_environment`関数によってインストールされます。主要なパッケージは以下の通りです。

- torch, torchvision, torchaudio: 深層学習の演算基盤
- opencv-python, pillow: 画像処理
- transformers: DINOv2モデルの利用
- pycolmap: COLMAP形式のデータ構造を扱うため
- numpy==1.26.4: 特定のバージョンに固定し、互換性の問題を回避
- scipy, psutil, tqdm: 科学計算、メモリ監視、プログレスバー表示などのユーティリティ

2.2 MASt3Rのセットアップ

3D再構築の中核を担うMASt3Rフレームワークは、`setup_mast3r`関数によって以下の手順でセットアップされます。

1. GitHubからMASt3Rのリポジトリをクローンします。
2. 依存関係にあるサブモジュール `dust3r` および `croco` をインストールします。
3. `requirements.txt` に記載された依存パッケージをインストールします。

4. 事前学習済みのモデルウェイト
(MASt3R_ViTLarge_BaseDecoder_512_catmlpdpt_metric.pth) をダウンロードします。
5. AsymmetricMASt3R モデルをインポートすることで、インストールが正常に完了したことを検証します。

2.3 Gaussian Splattingのセットアップ

最終的な3Dシーンを生成するGaussian Splattingフレームワークは、`setup_gaussian_splatting`関数によって以下の手順でセットアップされます。

1. GitHubからGaussian Splattingのリポジトリをクローンします。
2. Pythonの依存関係をインストールします。
3. パイプラインの性能に不可欠な2つのサブモジュール `diff-gaussian-rasterization` と `simple-knn` をビルドし、インストールします。

2.4 メモリ管理ユーティリティ

本パイプラインは、計算負荷の高い処理を安定して実行するために、以下のメモリ管理ユーティリティを備えています。

- **clear_memory()** : 各主要ステップの完了後に呼び出され、`torch.cuda.empty_cache()` を用いてGPUのキャッシュを解放し、`gc.collect()` を用いてCPUメモリのガベージコレクションを強制的に実行します。これにより、次の処理ステージで利用可能なメモリを最大化します。
- **get_memory_info()** : パイプライン実行中の任意の時点で、現在のGPUおよびCPUのメモリ使用状況をログに出力します。これにより、リソース消費の監視とボトルネックの特定が容易になります。

3.0 パイプライン構成要素とデータフロー

本セクションでは、パイプラインを構成する各要素の技術的な詳細を、データの流れに沿って段階的に解説します。画像の正規化から始まり、最終的な3Dモデルの学習に至るまで、各コンポーネントのアーキテクチャ上の目的、ロジック、入力、および出力を明らかにします。これにより、システム全体の動作原理を詳細に理解することができます。

3.1 ステップ1: 画像の前処理 (Biplet-Square Normalization)

この正規化ステージは、後続のモデルにおけるパフォーマンスの安定化に不可欠です。

`normalize_image_sizes_biplet`および`generate_two_crops`関数は、Biplet-Square戦略を採用し、単純な中央クロップと比較して周辺の視覚情報を最大限に保持します。これにより、特徴点マッチングのためのより豊かなコンテキストを提供します。プロセスは以下の通りです。

- 向きの判定: 各画像の幅と高さを比較し、横長 (landscape) か縦長 (portrait) かを判定します。
- デュアルクロッピング: 判定された向きに基づき、2つの重複する正方形のクロップを生成します。
- 横長画像の場合 (幅 W x 高さ H): 高さ H を一辺とする正方形を、座標(0, 0)からと($W-H$, 0)からの2箇所 で切り出します。
- 縦長画像の場合: 幅 W を一辺とする正方形を、座標(0, 0)からと(0, $H-W$)からの2箇所 で切り出します。
- リサイズ: 生成された各クロップ画像は、高品質なダウンサンプリングアルゴリズムである `Image.Resampling.LANCZOS` を用いて、指定された解像度 (例: `size=1024`) にリサイズされます。

3.2 ステップ2: 画像ペアの選定 (DINO-based Pair Selection)

get_image_pairs_dino関数は、3D再構築の計算効率を最大化するために、最も関連性の高い画像ペアをインテリジェントに選定します。そのメカニズムは以下の通りです。

1. 特徴抽出: 事前学習済みモデルであるDINOv2 (facebook/dinov2-base) を使用して、正規化された各画像からグローバルな特徴ベクトルを抽出します。このベクトルは、画像全体の視覚的な内容を要約したものです。
2. 類似度計算: 抽出された全画像の特徴ベクトルを用いて、総当たりの類似度行列 ($\text{sim} = \mathbf{g} @ \mathbf{g.T}$) を計算します。
3. **Top-K**ペアの構築: 各画像に対して、類似度行列に基づき最も類似度の高い上位 GLOBAL_TOPK (値: 20) の画像を特定し、初期の候補ペアを形成します。
4. 多様性を考慮したペア選定: 候補ペアの総数が定義された上限 (max_pairs) を超える場合、select_diverse_pairs戦略が適用されます。このアルゴリズムは、各画像がペアに登場する回数 (image_counts) を計算し、登場回数の少ない画像を含むペアを優先するスコア (pair_score) を算出します。これにより、視覚的な「ハブ」(少数の画像がペアを独占する状態) の形成を防ぎ、特に直線的な動きを持つデータセットにおいて、より空間的に頑健で完全な再構築を保証します。

3.3 ステップ3: 3D再構築 (MASt3R Reconstruction)

run_mast3r_pairs関数は、パイプラインの中核となる3D再構築処理を実行します。

1. モデルとデータの読み込み: 事前学習済みのAsymmetricMASt3Rモデルをメモリにロードします。同時に入力画像は、メモリ消費を抑制するため、低解像度 (MASt3R_IMAGE_SIZE = 224) にリサイズして準備されます。
2. 推論: 選定された画像ペアがモデルのinference関数に渡され、各ペア間の相対的なカメラポーズと深度情報が予測されます。
3. グローバルアライメント: inference関数の出力をglobal_aligner関数 (GlobalAlignerMode.PointCloudOptimizerモード) で処理し、全てのペアの情報を統合して、グローバルに一貫性のある3Dシーンを構築します。この際、最適化の反復回数は niter=150に設定され、精度と処理速度のバランスを取っています。

3.4 ステップ4: COLMAP形式へのデータ変換

このデータ変換ステージは、MASt3Rのネイティブなシーン表現を、Gaussian Splattingが要求する厳格で標準化されたCOLMAPバイナリ形式へと meticulously (細心の注意を払って) 変換する、極めて重要な橋渡し役を担います。

1. データ抽出: MASt3Rのsceneオブジェクトから、3D点の座標 (pts3d)、色情報、カメラポーズ、および焦点距離を抽出します。
2. ポイントクラウドのダウンサンプリング: 3D点の総数が指定された上限 (max_points) を超える場合、ランダムサンプリングによって点の数を削減します。これは、後続の処理におけるメモリオーバーフローを防ぐための重要な安全機構です。
3. ポーズ変換: 最も重要な処理として、MASt3Rが出力する **camera-to-world (c2w)** 形式のカメラポーズを、np.linalg.inv を用いて逆行列を計算し、COLMAPが要求する **world-to-camera (w2c)** 形式に変換します。さらに、3x3の回転行列はrotmat2qvec関数によって、images.bin形式で要求される4要素のクォータニオン (w, x, y, z) に変換されます。
4. カメラ内部パラメータのスケーリング: MASt3Rの内部処理サイズ (224x224) に基づいて計算された焦点距離 (focals) と主点 (pp) を、元の処理済み画像の寸法に合わせてスケーリングします。

- バイナリ形式でのシリアルライズ: 処理された全てのデータ(カメラ、画像、3D点)を、cameras.bin、images.bin、points3D.bin という3つのCOLMAP標準バイナリファイルに直接書き込みます。

3.5 ステップ5: Gaussian Splattingモデルの学習

パイプラインの最終ステージであるtrain_gaussian_splatting関数は、生成されたCOLMAPデータを用いて3Dシーンを完成させます。

- 入力: このステージの入力は、前ステップで生成されたCOLMAPバイナリファイルを含むディレクトリと、処理済み画像が格納されたディレクトリです。
- 学習の実行: Gaussian Splattingリポジトリ内の train.py スクリプトを、subprocessコールを介して実行します。
- パフォーマンスチューニングパラメータ: 学習中のパフォーマンスとメモリ使用量を管理するために、以下の主要なコマンドライン引数を使用されます。
- resolution 2: 画像解像度を1/2に下げてメモリ負荷を軽減します。
- densify_grad_threshold 0.001: 密度の閾値を高く設定し、生成されるガウス(点)の数を抑制します(a higher threshold reduces the number of Gaussians created)。
- densification_interval 200: ガウスの密度を高める処理の頻度を下げ、計算量を削減します(densifying less frequently to lower computational load)。
- 出力: 学習が完了すると、指定された出力ディレクトリ内に最終的な成果物である学習済みポイントクラウドモデル (point_cloud.ply) が生成されます。

4.0 設定パラメータ

本パイプラインは、設定パラメータを通じて、様々なデータセット、ハードウェア制約、および要求される出力品質に柔軟に対応する能力を備えています。これらのパラメータは、パイプラインの挙動を精密に制御するための重要なインターフェースとなります。

4.1 グローバル設定

Configクラスで定義されるこれらのパラメータは、パイプライン全体の基本的な動作を規定します。| パラメータ (Parameter) | 値 (Value) | 説明 (Description) || ----- | ----- | ----- || N_KEYPOINTS | 8192 | 特徴点抽出の最大数。|| IMAGE_SIZE | 1024 | Bipler-Square Normalization後の画像サイズ。|| GLOBAL_TOPK | 20 | DINOペア選定で各画像に対して選ぶ類似ペアの最大数。|| DINO_MODEL | "facebook/dinov2-base" | 特徴抽出に使用するDINOモデルのパス。|| MAST3R_MODEL | ../MASt3R_ViT...pth | 事前学習済みのMASt3Rモデルのパス。|| MAST3R_IMAGE_SIZE | 224 | MASt3Rの推論時に使用する画像サイズ。メモリ節約のために小さく設定。|| DEVICE | 'cuda' or 'cpu' | 計算に使用するデバイス。|

4.2 パイプライン実行時パラメータ

main_pipeline関数の引数として渡されるこれらのパラメータは、個別の実行ごとにパイプラインの挙動を調整するために使用されます。| パラメータ (Parameter) | デフォルト値の例 | 説明 (Description) || ----- | ----- | ----- || square_size | 1024 | 画像の前処理における目標正方形サイズ。|| iterations | 1000 | Gaussian Splattingの学習イテレーション数。|| max_images | 30 | 処理する元の画像の最大枚数。|| max_pairs | 1000 | MASt3Rによる再構築に使用する画像ペアの最大数。|| max_points | 1000000 | COLMAP形式に変換する3Dポイントの最大数。|

5.0 主要な技術的決定事項

本パイプラインの有効性は、個々の処理ステップだけでなく、速度、リソース管理、および最終的な再構築品質を向上させるために行われた、いくつかの重要なアーキテクチャ上の決定に基づ

いています。本セクションでは、これらの極めて重要な選択の背景にある論理的根拠を分析します。

5.1 COLMAPの代替としてのMASt3R採用

従来のSfMパイプラインをMASt3Rで置き換えるという戦略的判断は、初期再構築フェーズを根本的に変革します。この決定により、特徴点抽出、マッチング、幾何学的検証、インクリメンタルな再構築といった、脆弱で複数のステージからなるプロセスが、単一のエンドツーエンドな微分可能モデルに統合されます。結果として、障害点と設定の複雑さが大幅に削減され、より堅牢で予測可能なワークフローが実現します。

5.2 Biplet-Square Normalizationの役割

単純な中央クロップではなく、デュアルクロップ方式であるBiplet-Square Normalizationを採用したことは、再構築の頑健性を高める上で重要な役割を果たします。この手法は、元画像の周辺部から失われがちな視覚情報を意図的に保持します。保持されたデータは、特徴点マッチングの際により多くの文脈を提供し、特に画像間のオーバーラップが少ない場合に、より正確で安定したカメラポーズ推定につながる可能性があります。

5.3 厳密なメモリ管理戦略

本パイプラインの設計思想の中核には、「リソースを意識した設計哲学」があります。これは単一の機能ではなく、限られたハードウェアリソースでの実行可能性を確保するための一貫した戦略です。この戦略は、抽象度の異なる複数のレベルで機能します。

- 推論レベル: 最も計算集約的なMASt3Rの推論ステップにおいて、入力画像の解像度をMASt3R_IMAGE_SIZE=224に下げることによって、GPUメモリのフットプリントを劇的に削減します。
- データ構造レベル: max_pointsパラメータを用いてポイントクラウドの最大数を制限することで、データ変換およびGaussian Splatting学習段階でのメモリ枯渇を防ぐ、極めて重要な安全装置として機能します。
- プロセスレベル: max_pairsパラメータでMASt3Rが処理するペア数を制限し、再構築の範囲とリソース消費を直接的に制御します。さらに、clear_memory()による明示的なガベージコレクションは、主要ステージ間でリソースを確実に解放し、パイプライン全体の安定性を保証します。これらのアーキテクチャ上の決定が統合されることで、本パイプラインは単に機能的であるだけでなく、現実世界の制約（例えば限られたGPUメモリ）に対して堅牢で、効率的かつ適応性の高いシステムとなります。これらの戦略的選択の集合体が、現代の3D再構築タスクに対応可能な、信頼性の高いパイプラインを構築しているのです。